




R&D for (Open) Large Language Models in Norway


Stephan Oepen, Language Technology Group (LTG, University of Oslo)

September 29, 2026 – NorwAI Innovate at the Trondheim Tech Festival

O


**Background,
Preliminaries**






Språklig og kulturell identitet

- ▶ I helgen var *jeg* på hytten i *skogen* og danset med min *søster*.
- ▶ I helga var *jeg* på hytta i *skauen* og dansa med *søster*a mi.
- ▶ I helga var *eg* på hytta i *skogen* og dansa med *syster*a mi.
- ▶ I helga var *eg* på hytta i *skogen* og dansa med *søster*a mi.



Språklig og kulturell identitet

- ▶ *I helg**en** var jeg på hytt**en** i skogen og dans**et** med min søster.*
- ▶ *I helg**a** var jeg på hytt**a** i skauen og dans**a** med søstera mi.*
- ▶ *I helg**a** var eg på hytt**a** i skogen og dans**a** med systera mi.*
- ▶ *I helg**a** var eg på hytt**a** i skogen og dans**a** med søstera mi.*



Språklig og kulturell identitet

- ▶ *I helgen var jeg på hytten i skogen og danset med **min søster**.*
- ▶ *I helga var jeg på hytta i skauen og dansa med **søstera mi**.*
- ▶ *I helga var eg på hytta i skogen og dansa med **systera mi**.*
- ▶ *I helga var eg på hytta i skogen og dansa med **søstera mi**.*



Språklig og kulturell identitet

- ▶ *I helgen var jeg på hytten i skogen og danset med min søster.*
- ▶ *I helga var jeg på hytta i skauen og dansa med søstera mi.*
- ▶ *I helga var eg på hytta i skogen og dansa med systera mi.*
- ▶ *I helga var eg på hytta i skogen og dansa med søstera mi.*

By Way of Self-Introduction (Gemma-4-21b-it)

By Way of Self-Introduction (Gemma-4-21b-it)

What makes Stephan Oepen at the University of Oslo tick in terms of his academic work?



Reasoning >

Based on his publications, research projects, and academic trajectory, Stephan Oepen's work at the University of Oslo is driven by a desire to bridge the gap between **formal linguistic theory** and **modern machine learning**.

While many in the current NLP (Natural Language Processing) field treat language as a sequence of tokens to be predicted by a "black box" model, Oepen is motivated by the underlying **structure** of language.

By Way of Self-Introduction (Gemma-4-21b-it)

What makes Stephan Oepen at the University of Oslo tick in terms of his academic work?



Reasoning >

Based on his publications, research projects, and academic trajectory, Stephan Oepen's work at the University of Oslo is driven by a desire to bridge the gap between **formal linguistic theory** and **modern machine learning**.

While many in the current NLP (Natural Language Processing) field treat language as a sequence of tokens to be predicted by a "black box" model, Oepen is motivated by the underlying **structure** of language.

• • •

Summary: The "Philosophical" Driver

If you had to distill what drives him, it is the belief that **language is not just a statistical pattern, but a structured system**.

“Hallucination” Remains a Challenge

Here is a breakdown of what "makes him tick" academically:

1. The Quest for Structure (Parsing)

At the core of Oepen's work is **parsing**—the process of analyzing a string of symbols to determine its grammatical structure. He has spent a significant portion of his career exploring:

- **Dependency Parsing:** How words relate to one another in a hierarchy.

“Hallucination” Remains a Challenge

Here is a breakdown of what "makes him tick" academically:

1. The Quest for Structure (Parsing)

At the core of Oepen's work is **parsing**—the process of analyzing a string of symbols to determine its grammatical structure. He has spent a significant portion of his career exploring:

- **Dependency Parsing:** How words relate to one another in a hierarchy.

• • •

3. Multilingualism and Low-Resource Languages

A significant motivator for Oepen is the democratization of NLP. Much of the field's progress is centered on English. Oepen focuses on:

- **Cross-lingual Transfer:** Using knowledge from a high-resource language (like English) to help a model understand a low-resource language.
- **Universal Dependencies:** He contributes to the effort of creating a consistent framework for grammar across different languages, allowing for a more unified theory of computational linguistics.

“Hallucination” Remains a Challenge

Here is a breakdown of what "makes him tick" academically:

1. The Quest for Structure (Parsing)

At the core of Oepen's work is **parsing**—the process of analyzing a string of symbols to determine its grammatical structure. He has spent a significant portion of his career exploring:

- **Dependency Parsing:** How words relate to one another in a hierarchy.

• • •

3. Multilingualism and Low-Resource Languages

A significant motivator for Oepen is the democratization of NLP. Much of the field's progress is centered on English. Oepen focuses on:

- **Cross-lingual Transfer:** Using knowledge from a high-resource language (like English) to help a model understand a low-resource language.
- **Universal Dependencies:** He contributes to the effort of creating a consistent framework for grammar across different languages, allowing for a more unified theory of computational linguistics.

The ChatGPT Lawyer Explains Himself

In a cringe-inducing court hearing, a lawyer who relied on A.I. to craft a motion full of made-up case law said he “did not comprehend” that the chat bot could lead him astray.



1

The Situation in Norway

Februar 5: Renewed and Intensified Collaboration



 Nasjonalbiblioteket

 NTNU



UNIVERSITETET
I OSLO

 sigma2

Språkrådet 

Det norske LLM-økosystemet i dag (som vi forstår det)

Det norske LLM-økosystemet i dag (som vi forstår det)

NTNU & UiO (& Nasjonalbiblioteket) – Grunnleggende og anvendt forskning

NOE AKTIVITET I NASJONALE OG EUROPEISKE ENKELTPROSJEKTER;
STERK FRAGMENTERING; INGEN KI-SENTER HAR SPRÅKMODELLER I FOKUS.

Det norske LLM-økosystemet i dag (som vi forstår det)

NTNU & UiO (& Nasjonalbiblioteket) – Grunnleggende og anvendt forskning

NOE AKTIVITET I NASJONALE OG EUROPEISKE ENKELTPROSJEKTER;
STERK FRAGMENTERING; INGEN KI-SENTER HAR SPRÅKMODELLER I FOKUS.

Nasjonalbiblioteket – «Språkmodellfabrikken»

UTVIKLING AV «PRODUKSJONS»-MODELLER FOR NORSK OG SAMISKE SPRÅK;
STATSBUDSJETT 2025 & 2026: GRUNNBEVILGNING, DOG IKKE FORSKNING.

Det norske LLM-økosystemet i dag (som vi forstår det)

NTNU & UiO (& Nasjonalbiblioteket) – Grunnleggende og anvendt forskning

NOE AKTIVITET I NASJONALE OG EUROPEISKE ENKELTPROSJEKTER;
STERK FRAGMENTERING; INGEN KI-SENTER HAR SPRÅKMODELLER I FOKUS.

Nasjonalbiblioteket – «Språkmodellfabrikken»

UTVIKLING AV «PRODUKSJONS»-MODELLER FOR NORSK OG SAMISKE SPRÅK;
STATSBUDSJETT 2025 & 2026: GRUNNBEVILGNING, DOG IKKE FORSKNING.

Sigma2 – Styrket GPU-kapasitet og tungregningskompetanse

STORSKALA FORSKNINGSINFRASTRUKTUR AVGJØRENDE LLM-DRIVKRAFT;
SAMMENLIGNET MED FINLAND ELLER SVEITS LIGGER NORGE LANGT BAK.

Det norske LLM-økosystemet i dag (som vi forstår det)

NTNU & UiO (& Nasjonalbiblioteket) – Grunnleggende og anvendt forskning

NOE AKTIVITET I NASJONALE OG EUROPEISKE ENKELTPROSJEKTER;
STERK FRAGMENTERING; INGEN KI-SENTER HAR SPRÅKMODELLER I FOKUS.

Nasjonalbiblioteket – «Språkmodellfabrikken»

UTVIKLING AV «PRODUKSJONS»-MODELLER FOR NORSK OG SAMISKE SPRÅK;
STATSBUDSJETT 2025 & 2026: GRUNNBEVILGNING, DOG IKKE FORSKNING.

Sigma2 – Styrket GPU-kapasitet og tungregningskompetanse

STORSKALA FORSKNINGSINFRASTRUKTUR AVGJØRENDE LLM-DRIVKRAFT;
SAMMENLIGNET MED FINLAND ELLER SVEITS LIGGER NORGE LANGT BAK.

KI Norge & *New Nordics AI* – KI-basert innovasjon, tilsyn, regulering

BRED TOLKNING AV KI; IKKE FOKUS PÅ FORSKNING ELLER SPRÅKMODELLER.

8. juni: Nasjonal statusmelding og «Klyngas anbefalinger»

 Språkmodellklynge Norge Om oss

 Nasjonalbiblioteket  NTNU  UNIVERSITETET I OSLO


 sigma2 Språkrådet

Nasjonal statusmelding: Forskning og utvikling for store, åpne språkmodeller i Norge

kontakt@språkmodellklynge.no

Anbefalinger

Av hensyn til så vel digital som kulturell suverenitet må Norge etablere og drifte et helhetlig nasjonalt økosystem for utvikling, evaluering og anvendelse av egne, trygge og åpne språkmodeller. Det forutsetter blant annet styrket forskningskompetanse og -kapasitet, storskala GPU-infrastruktur, tjenester for data- og modelldeling, samt rammer for samspill mellom grunnleggende forskning og praktisk anvendelse, inkludert styrket nordisk og europeisk samarbeid. Det kreves rask og koordinert handling på regjeringsnivå, inkludert samhandling med for eksempel Norges forskningsråd og Nordisk ministerråd. Språkmodellklynge Norge anbefaler å:



<https://språkmodellklynge.no/>

1.

lgangsette en hurtigarbeidende prosess mot en helhetlig nasjonal LLM-strategi, med reell involvering av de sentrale norske forskningsmiljøene sammen med øvrige nasjonale aktører.

1.

Igangsette en hurtigarbeidende prosess mot en helhetlig nasjonal LLM-strategi, med reell involvering av de sentrale norske forskningsmiljøene sammen med øvrige nasjonale aktører.

2.

Etablere et nasjonalt KI-forskningsenter for åpne språkmodeller som samler aktørene i et faglig fellesskap, med en tilhørende forskerskole. I et femårsperspektiv bør det utdannes 15–20 doktorgrader.

1. Igangsette en hurtigarbeidende prosess mot en helhetlig nasjonal LLM-strategi, med reell involvering av de sentrale norske forskningsmiljøene sammen med øvrige nasjonale aktører.
2. Etablere et nasjonalt KI-forskningsenter for åpne språkmodeller som samler aktørene i et faglig fellesskap, med en tilhørende forskerskole. I et femårsperspektiv bør det utdannes 15–20 doktorgrader.
3. Videreutvikle Sigma2 som nasjonal leverandør av regnekraft, LLM-tjenester og tungregningskompetanse, herunder utvidet norsk engasjement i europeiske tungregningsinfrastrukturer som LUMI-AIF og EuroHPC.

4.

Stimulere til nordisk forsknings- og utviklingssamarbeid gjennom blant annet data- og modelldeling, forskermobilitet, koordinert forskerutdanning, en årlig nordisk møteplass for forskere og utviklere av åpne språkmodeller.

4.

Stimulere til **nordisk forsknings- og utviklingssamarbeid** gjennom blant annet data- og modelldeling, forskermobilitet, koordinert forskerutdanning, en **årlig nordisk møteplass** for forskere og utviklere av åpne språkmodeller.

5.

Utvikle **rettslige og praktiske rammer** for datadeling, som balanserer opphavsrett og personvern med behovene for **trening på storskala data** og for **inspeksjon og validering** av modeller.

4.

Stimulere til **nordisk forsknings- og utviklingssamarbeid** gjennom blant annet data- og modelldeling, forskermobilitet, koordinert forskerutdanning, en **årlig nordisk møteplass for forskere og utviklere** av åpne språkmodeller.

5.

Utvikle **rettslige og praktiske rammer** for datadeling, som balanserer opphavsrett og personvern med behovene for **trening på storskala data** og for **inspeksjon og validering** av modeller.

6.

Etablere norsk medlemskap i det **europiske *Alliance for Language Technologies*** (ALT-EDIC) og økonomiske rammer for deltakelse fra universitetsmiljøer i ***Digital Europe***-programmet.

Flere FoU-medlemmer og observatører

SAMISKE FAGMILJØER VED SÁMI ALLASKUVLA OG UIT;
UIB, UIS, NR, SIMULA, ...; KI NORGE.

Flere FoU-medlemmer og observatører

SAMISKE FAGMILJØER VED SÁMI ALLASKUVLA OG UIT;
UIB, UIS, NR, SIMULA, ...; KI NORGE.

Felles forskningsinfrastruktur: data, evaluering, programvare

ENHETLIG OPPSETT PÅ OLIVIA OG LUMI; STANDARDISERT EVALUERING;
SAMARBEID MED ALT-EDIC: NORSK INSTANS AV COMPAR:IA-ARENA.

Flere FoU-medlemmer og observatører

SAMISKE FAGMILJØER VED SÁMI ALLASKUVLA OG UIT;
UIB, UIS, NR, SIMULA, ...; KI NORGE.

Felles forskningsinfrastruktur: data, evaluering, programvare

ENHETLIG OPPSETT PÅ OLIVIA OG LUMI; STANDARDISERT EVALUERING;
SAMARBEID MED ALT-EDIC: NORSK INSTANS AV COMPAR:IA-ARENA.

30. november & 1. desember: *Nordic LLM Summit*

30–40 FORSKERE FRA DANMARK, ISLAND, FINLAND, SVERIGE: «HANDS-ON»;
KOORDINERING, MULIG SAMARBEID, F.EKS. DATADELING, EVALUERING.

...


2

**Over There
in Europe**

For eksempel: Europas største FoU-initiativ på området



The Consortium: 21 Partners, 9 European Countries



UNIVERSITY OF HELSINKI



ellamind



CINECA



The Consortium: 21 Partners, 9 European Countries



Charles
University

AMD
SILO AI

alt-edu
ELDA

EBERHARD KARLS
UNIVERSITÄT
TÜBINGEN



e l l i s
INSTITUTE
TÜBINGEN



Fraunhofer
IAIS



JÜLICH
Forschungszentrum

TU/e
EINDHOVEN
UNIVERSITY OF
TECHNOLOGY



UNIVERSITY OF HELSINKI



UNIVERSITY
OF TURKU



ALEPH
ALPHA

AI
SWEDEN

ellamind

Lighton

prompsit



BSC
Barcelona
Supercomputing
Center
Centro Nacional de Supercomputación


CINECA



CSC

SURF

The Consortium: 21 Partners, 9 European Countries



UNIVERSITY OF HELSINKI



ellamind

Lighton

prompsit




Barcelona
Supercomputing
Center
Centro Nacional de Supercomputación

CINECA



SURF

The Consortium: 21 Partners, 9 European Countries



Barcelona
Supercomputing
Center
Centro Nacional de Supercomputación

CINECA



SURF



The Mission: Digital Sovereignty – Transparent AI

Linguistic Equity

36⁺ languages: member states, candidate members, close associates;
emphasize multilingual evaluation: new datasets and benchmarks.

Linguistic Equity

36⁺ languages: member states, candidate members, close associates;
emphasize multilingual evaluation: new datasets and benchmarks.

Open Models & Data

Share models under permissive open-source licenses (e.g. Apache 2.0);
make complete and exact training data generally available for verification.

Linguistic Equity

36⁺ languages: member states, candidate members, close associates;
emphasize multilingual evaluation: new datasets and benchmarks.

Open Models & Data

Share models under permissive open-source licenses (e.g. Apache 2.0);
make complete and exact training data generally available for verification.

Verifiable Openness

Open-source & document full pipeline: code, recipes, results.

The Mission: Digital Sovereignty – Transparent AI

Linguistic Equity

36⁺ languages: member states, candidate members, close associates;
emphasize multilingual evaluation: new datasets and benchmarks.

Open Models & Data

Share models under permissive open-source licenses (e.g. Apache 2.0);
make complete and exact training data generally available for verification.


Verifiable Openness

Open-source & document full pipeline: code, recipes, results.

Reusable Infrastructure

Uniform data management, tools, workflows across EuroHPC ecosystem.

Project Lifecycle: Preparation – Production – Flagship



COLLABORATION – DATA MIXTURES – INFRASTRUCTURE – EVALUATION

EuroHPC Joint Undertaking - Resources for strategic initiatives:

OpenEuroLLM granted substantial **compute** on all major **EuroHPC** supercomputers for developing LLMs for all EU languages



Co-funded by
the European Union

Regnekraft, nok en gang: OpenEuroLLMs GPU-kalkulator

	A	B	C	D	E	F	G	H	I	J	K
1											
2											
3											
4											
5											
6											
7											
8											
9											
10											
11											
12											
13											
14											
15											

Parameter	Value
Model parameters (N) (billions)	32
Training tokens (D) (trillions)	15
Wasted compute	20%

Training compute (FLOPs) 2.88E+24

Total GPUh by system

System	TFLOPS	GPUh
JUPITER	400	2.40M
MN5	400	2.40M
LUMI	140	6.86M
Leonardo	150	6.40M

Continuous compute days by system and node count

Nodes	64	128	256	512	1024
Days on JUPITER	391	195	98	49	24
Days on MN5	391	195	max nodes 128		
Days on LUMI	1116	558	279	140	70
Days on Leonardo	1042	521	260	130	max

NB: estimates do not include time on queue, system downtimes, etc.
Calendar days to complete can be double the continuous compute days or more.

GRUNNTRENING AV MELLOMSTOR MODELL KREVER EUROPEISK SAMARBEID;
(ELLER EN SATSING À LA SVEITS; OLIVIA ER OM LAG 1/24-DEL AV ALPS).

3

**Norwegian in
OpenEuroLLM**

2025 Pretraining Data Mix: 10 Trillion Tokens

```
stoepen@uan02:~/training/collection/baby> ./etc/plan.py --budget datamix.txt | egrep "nno|nob"
finepdfs-1.0.0/megatron-lm/nno_Latn: 3,150m tokens of 340m (926.5%).
finepdfs-1.0.0/megatron-lm/nob_Latn: 3,080m tokens of 9,974m (30.9%).
finepdfs-edu-1.0.0/megatron-lm/nno_Latn: 40m tokens of 41m (97.6%).
finepdfs-edu-1.0.0/megatron-lm/nob_Latn: 1,300m tokens of 1,300m (100.0%).
hplt-3.0/megatron-lm/nno_Latn: 9,970m tokens of 1,420m (702.1%).
hplt-3.0/megatron-lm/nob_Latn: 13,700m tokens of 44,588m (30.7%).
nemotron-cc-tower+-0.1/megatron-lm/parallel/tower9b/nno_Latn: 6,780m tokens of 90,132m (7.5%).
nemotron-cc-tower+-0.1/megatron-lm/parallel/tower9b/nob_Latn: 9,320m tokens of 84,161m (11.1%).
```

Norwegian: *Bokmål* and *Nynorsk*

CLOSE TO 50B TOKENS FOR BOTH LANGUAGES: ABOUT 0.5 PERCENT;
ABOUT 40 PERCENT NYNORSK; HEAVILY UPSAMPLED (UP TO TEN TIMES);
USING ALL AVAILABLE NYNORSK, BUT ONLY ABOUT 1/3 OF ALL BOKMÅL;
ONE THIRD OF DATA (17B TOKENS) MACHINE TRANSLATED FROM ENGLISH.

2025 Pretraining Data Mix: 10 Trillion Tokens

```
stoepen@uan02:~/training/collection/baby> ./etc/plan.py --budget datamix.txt | egrep "nno|nob"
finepdfs-1.0.0/megatron-lm/nno_Latn: 3,150m tokens of 340m (926.5%).
finepdfs-1.0.0/megatron-lm/nob_Latn: 3,080m tokens of 9,974m (30.9%).
finepdfs-edu-1.0.0/megatron-lm/nno_Latn: 40m tokens of 41m (97.6%).
finepdfs-edu-1.0.0/megatron-lm/nob_Latn: 1,300m tokens of 1,300m (100.0%).
hplt-3.0/megatron-lm/nno_Latn: 9,970m tokens of 1,420m (702.1%).
hplt-3.0/megatron-lm/nob_Latn: 13,700m tokens of 44,588m (30.7%).
nemotron-cc-tower+-0.1/megatron-lm/parallel/tower9b/nno_Latn: 6,780m tokens of 90,132m (7.5%).
nemotron-cc-tower+-0.1/megatron-lm/parallel/tower9b/nob_Latn: 9,320m tokens of 84,161m (11.1%).
```

Norwegian: *Bokmål* and *Nynorsk*

CLOSE TO 50B TOKENS FOR BOTH LANGUAGES: ABOUT 0.5 PERCENT;
ABOUT 40 PERCENT NYNORSK; HEAVILY UPSAMPLED (UP TO TEN TIMES);
USING ALL AVAILABLE NYNORSK, BUT ONLY ABOUT 1/3 OF ALL BOKMÅL;
ONE THIRD OF DATA (17B TOKENS) MACHINE TRANSLATED FROM ENGLISH.

ENGLISH-FIRST PRETRAINING AS BEST PRACTICE – “GENERAL CAPABILITIES”

For Example, Translating from “High-Quality” English



Computer Science > Computation and Language

arXiv:2607.00890 (cs)

[Submitted on 1 Jul 2026]


MultiSynt/MT: Trillion-Token Multi-Parallel Pre-Training Data Translated Across 36 Languages

Maximilian Idahl, Jörg Tiedemann, Sampo Pyysalo, David Salinas, Tomasz Galica, Shenbin Qian, Tudor Nicolae Mateiu, Zihao Li, Anna Lokrantz, Fedor Vitiugin, André F. T. Martins, Jenna Kanerva, Filip Ginter, Matthias Lindemann, Tim Isbister, Birger Moell, Jonas Lindh, Jan Hajič, Jenia Jitsev, Andrey Kutuzov, Stephan Oepen, Gema Ramírez-Sánchez

View PDF

HTML (experimental)

Open web-scale pre-training corpora remain concentrated in English, limiting multilingual LLM development. We introduce MultiSynt/MT, an open synthetic parallel corpus with approximately 4.8 trillion target-language tokens across 36 European languages, produced by translating 100 billion high-quality NemoTron-CC tokens with Tower+ and OPUS-MT/HPLT-MT systems. For many medium- and lower-resource European languages, this is the largest openly available pre-training resource. On a broad multilingual benchmark suite, reference LLMs trained on MultiSynt/MT reach the final score of HPLT 2.0, a native-data baseline, using roughly 72% fewer pre-training tokens, and outperform it by approximately 15% relative at a matched 100B-token training budget. Our analyses also identify evaluation blind spots: standard multiple-choice




<https://arxiv.org/abs/2607.00890>

Your Mileage May Vary


Norwegian – NorIdiom (Bokmål; 0-shot) ▾

Task: NorIdiom (Bokmål) ▾ Shots: 0-shot 5-shot Prompt aggregation: max ▾ Normalization: random baseline ▾
Metric: exact match (first word) (default) ▾ Error bands: shown hidden



Norwegian – NRK Quiz QA (Bokmål; 0-shot) ▾

Task: NRK Quiz QA (Bokmål) ▾ Shots: 0-shot 5-shot Prompt aggregation: max ▾ Normalization: random baseline ▾
Metric: accuracy (default) ▾ Error bands: shown hidden





<https://ltgoslo.github.io/llm-dashboard/multisynt/?lang=Norwegian>

4



**Wrap-Up
Outlook**

A Handful of Overarching Reflections

Sveits, for eksempel: Alps & Apertus




Sveits, for eksempel: Alps & Apertus



THREE SITES (ETH, EPFL, CSCS): COHESIVE TEAM; **PRIORITIZED GPU ACCESS**;
CURRENTLY STRONGEST **FULLY OPEN, MULTILINGUAL** MODELS (9B & 70B).

Stephan Oepen

Language Technology Group
University of Oslo
oe@ifi.uio.no



<https://språkmodellklynge.no/>
<https://www.openeurolm.eu/>